역사 전투 기록 정보추출을 위한 근거 보존형 스키마와 자원 구축: 인천상륙작전 코퍼스 기반 연구

Provenance-Preserving Schema and Resource Construction for Information Extraction from Historical Battle Records: A Corpus Study of the Inchon Landing

요 약

본 논문은 문헌 기반 전투 시뮬레이션 제작을 위한 기반 계층으로서 역사 전투 기록에 대한 근거보존형 정보추출 스키마 및 자원 패키지 HBR-IE v1 (Historical Battle Record Information Extraction)을 제안한다. 연구의 목적은 다양한 전투 기록 문헌에서 event/entity/time/quantity를 evidence-row 수준으로 안정적으로 구조화하여 후속 데이터베이스 구축, 사건 병합, 질의, 시뮬레이션 연계의 공통 기반을 마련하는 데 있다. 이를 검증하기 위하여 인천상륙작전 관련 6종 공개 문헌을 사례 코퍼스로 동결하고, provenance-first, conservative canonicalization, same-row local grounding 원칙 아래 Unit/Place canonical backbone과 Time/Event/Quantity rule-driven layer를 설계하였다. 동결 패키지는 evidence rows 11,166개, unit lexicon 224개, unit mapping 11,076개, place gazetteer 582개, place mapping 9,183개, 14개 event family, slot matrix 141개 row를 포함한다. 또한 120-row pilot과 48개 ambiguity row adjudication 결과, 반복 불안정성은 주로 decision asset·guideline·boundary rule 정교화로 해소되었고 schema structural change는 발생하지 않았다. 본 연구는 역사 전투 기록 일반을 위한 정보추출 기준안을 제시하고, 그 타당성을 인천상륙작전 코퍼스를 통해 실험적으로 검증하였다.

1. 서 론

인천상륙작전 core corpus는 1950년 9월 15일 상륙, 18일 김포공항 확보, 19–28일 서울 시가전, 26일 오산 북방 연결까지가 연속적으로 기록되어 있어 Land, Move, OccupyOrCapture, BombardOrFire, Cross, LinkUp이 복합적으로 공존하는 대표적 historical battle record 사례이다[1-6]. 그러나 실제 사료는 한국어·영어 장문 서술, 지휘제대 약칭, 상대지명, 단계표지, 수량표현이 혼재되어 있어 곧바로 database field나 simulation object로 치환하면 사건 동일성 병합, 부모제대 추정, 시간 앵커 강제와 같은 과잉추론이 발생한다.

정보추출의 관점에서 사건·개체 구조화는 MUC의 template-filling 전통[7]과 ACE의 trigger-argument 중심 event guideline[8]을 통해 정교화되었고, 시간 정보 표지는 TimeML과 TimeBank가 event, timex, temporal relation의 분리 원칙을 제시하였다[9,10]. 또한 주석 자산 설계는 iterative guideline refinement와 도구 친화적 span/event 분리를 갖는 annotation development cycle이 중요하다고 알려져 있다[11,12]. 그러나 이러한 계보는 주로 뉴스·일반 문서 중심으로 발전했기 때문에, 부대 계층과 relative place, phase marker가 밀집한 역사 전투기록에 그대로 적용하기 어렵다.

본 연구는 이를 BattleIR 이전 단계의 ingress-layer problem으로 재정의하고, 역사 전투 기록 일반에 적용 가능한 HBR-IE v1을 schema/resource paper로 제시한다. 인천상륙작전 핵심 말뭉치는 이 기준안의 타당성을 시험하기 위한 사례 코퍼스로 사용하였다. 기여는 (1) 6-source bilingual core corpus 동결, (2) evidence-row local grounding을 전제로 한 provenance-preserving 및 canonical/rule sheet 자원 패키지 구축, (3) 120-row pilot과 adjudication을 통한 v1 freeze 확정이다.

2. 핵심 말뭉치와 과업 정의

핵심 말뭉치는 Figure 1과 같이 공개 강한 텍스트 6종으로 제한하였다[1-6]. 구성은 한국군 관점 backbone 1종, 미 육군 campaign narrative 2종, 미 해병 D-Day·서울 시가전 상세 3종이다. 각 문헌은 1950-09-10~09-28과 Inchon/Seoul operation에 직접 대응하는 절만 발췌하고 page number와 section header를 보존하였다. 반면 National Archives viewer, timeline, monthly article 계열은

weak/background source로만 유지하였다. 이 선택은 Paper 1을 full system paper가 아닌 schema/resource paper로 한정하고, strong textual source의 교차검증 가능성을 우선하기 위한 것이다.

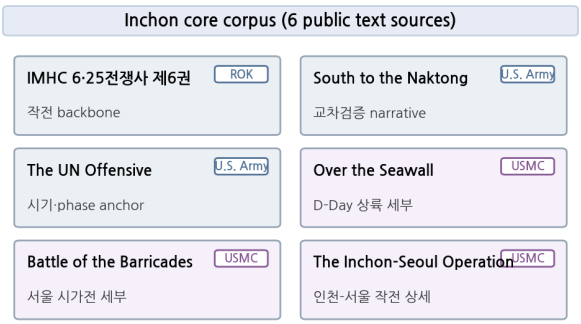

그림 1. 인천상륙작전 core corpus와 문헌 역할

HBR-IE v1의 기본 주석 단위는 frozen evidence backbone의 evidence row이다. 한 row에는 0–n개의 event와 0–n개의 unit/place/time/quantity expression이 공존할 수 있으며, slot filling은 같은 row가 직접 허가하는 surface에 한정한다. 따라서 현재 단계의 목표는 cross-evidence event merge나 전역 시뮬레이션 모델 생성이 아니라, 이후 계층이 신뢰할 수 있는 evidence-row local grounding을 제공하는 데 있다.

3. HBR-IE v1 설계

Figure 2는 v1 패키지 구조를 요약한다. Schema는 raw layer 위의 additive interpretation layer이며, Unit/Place는 canonical backbone, Time/Event/Quantity는 rule-driven layer로 분리하였다. 모든 instance는 source_id, evidence_id, page_ref, evidence_span을 유지한다. Event typing은 trigger-centered이고 assertion_status는 asserted, planned, failed, hypothetical, negated를 event family와 독립적으로 기록한다. v1은 14 event families와 141-row slot matrix를 채택하였다.

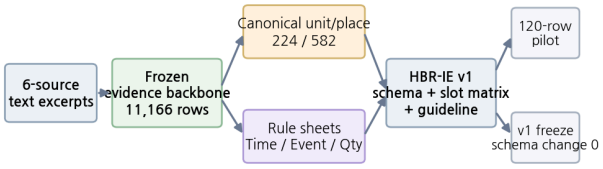

그림 2. provenance-first ingress architecture

설계 원칙은 ACE류 event typing과 TimeML류 time normalization을 역사 전투기록에 맞게 보수적으로 재배치하는 것이다[8-10]. 구체적으로 generic force expression은 formal unit으로 승격하지 않고, command/corps/division/regiment/battalion 경계를 붕괴시키지 않으며, same-row parent chain이 없는 bare regiment/battalion/company reference는 unresolved로 남긴다. 또한 weak anchor를 가진 relative expression은 named place로 강제 매핑하지 않고, daypart/phase-relative time은 강한 anchor가 없으면 partial 또는 relational 상태를 유지한다. Quantity layer에서는 unit designator numeral을 troop strength로 오인하지 않도록 unit_subcomponent_count, ship_count, landing_craft_count, casualty subtype을 분리하였다.

현재 동결된 resource package는 evidence rows 11,166개, unit lexicon 224행, unit mapping 11,076행(mapped 4,641; generic_group 2,349; unresolved 4,063), place gazetteer 582행, place mapping 9,183행(mapped 8,431; relative 713), issue registry 4,435행으로 materialize되었다. 이 수치는 schema를 추상 선언에 머물지 않게 하고, 이후 annotation과 retrieval 실험에서 같은 authority를 공유하게 만드는 실체적 기반이다.

반복적으로 충돌한 부분은 event family 자체보다 boundary decision이었다. Figure 3에 제시한 것처럼 상륙 순간과 내륙 이동은 Land/Move로 분리하고, 공격 행위와 통제 획득은 Attack/OccupyOrCapture로 분리하며, fire-delivery act는 Attack으로 흡수하지 않는다. 또한 barrier traversal semantics가 분명할 때만 Cross를 사용하고, planned/failed/hypothetical discourse는 event family가 아니라 assertion_status에서 처리한다. 이 원칙은 historical narrative의 과잉 정규화를 방지하고, 후속 merge 단계가 어떤 추론을 추가했는지 역추적 가능하게 만든다.

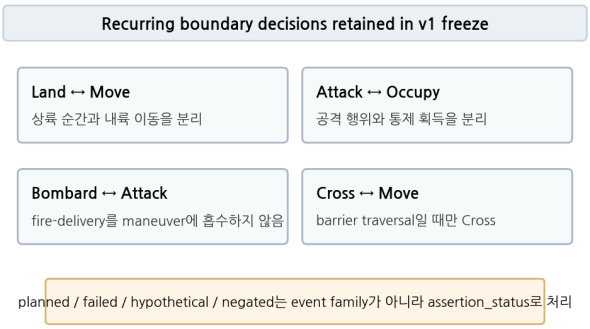

그림 3. v1 freeze에서 유지된 핵심 boundary decision

4. 파일럿과 v1 freeze

Pilot은 6개 문헌군을 균형 있게 반영하는 120개 evidence row로 구성하고, 14개 event family와 review/non-event row를 함께 포함하도록 설계하였다. 검증 초점은 span consistency, conservative entity/reference handling, trigger-centered typing, same-row slot filling 안정성에 두었다. 특히 low-echelon unit, relative/descriptive place, phase-relative time, quantity/designator boundary를 의도적으로 포함하여 rule sheet의 강건성을 시험하였다.

완료된 pilot에서는 ambiguity row 48개가 검토되었고 10개 recurring cluster로 수렴하였다. Figure 4와 같이 수정은 boundary rule 23건, decision table 13건, examples/quick reference 6건, guideline wording 3건으로 흡수되었고 schema structural change는 0건이었다. 따라서 event family inventory, slot admissibility, canonical unit/place resource, evidence-row annotation unit은 모두 유지되었다.

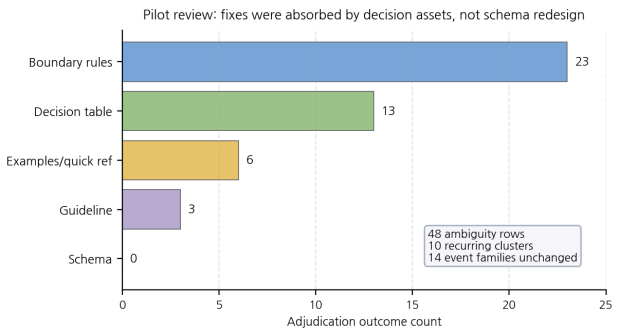

그림 4. pilot adjudication 결과와 수정 자산 분포

이 결과는 반복 불안정성이 schema 구조 부족보다 decision asset 정밀화로 해결되었음을 보여준다. 즉 pilot은 새로운 event type이나 slot 추가를 요구하지 않았고, 오히려 v1 authority를 annotation-ready 상태로 동결하는 기능을 수행하였다. 이는 이후 Paper 1 작성, pilot annotation 확대, database input, simulation pre-processing이 동일한 기준 자산을 공유할 수 있음을 의미한다.

5. 결 론

본 연구는 특정 전투를 위한 전용 스키마가 아니라, 역사 전투 기록 일반에 적용 가능한 HBR-IE v1의 schema/resource 기준안을 제시하고 이를 인천상륙작전 코퍼스에 적용해 실행 가능성을 검증하였다. 연구의 의의는 첫째, 전투 서술을 evidence-row 단위의 근거보존형 구조로 전환하여 후속 검증 가능성을 유지하는 ingress layer를 명시적으로 제도화한 점에 있다. 둘째, Unit/Place의 보수적 정준화와 Time/Event/Quantity의 규칙 기반 분리를 통해 고전 군사 서술의 모호성과 불완전성을 강제로 평탄화하지 않는 데이터베이스 설계 원칙을 구체화하였다. 셋째, 120-row pilot과 v1 freeze 결과를 통해 초기 안정화의 핵심이 schema 확장보다 decision asset 정교화에 있음을 실증하였다. 따라서 HBR-IE v1은 인천상륙작전 자체를 위한 모델이 아니라, 향후 다양한 시대·전구·언어의 전투 기록을 동일한 기준으로 축적·비교할 수 있는 역사 전투 기록 데이터베이스의 기초 계층으로 기능한다. 향후 연구에서는 인천상륙작전 외 전투사 코퍼스로 적용 범위를 확대하여 schema portability를 검증하고, cross-evidence event merge 및 BattleIR construction을 통해 occurrence-level 연결성을 강화하며, 지도·작전도·전투상보 등 멀티모달 사료를 결합한 simulation-facing representation으로 발전시켜 문헌 기반 역사 전투 시뮬레이션 애니메이션 제작 파이프라인과 연결할 필요가 있다.

참 고 문 헌

1. 국방부 군사편찬연구소, 『6·25전쟁사 제6권: 인천상륙작전과 반격작전』, 국방부 군사편찬연구소, 2009.
2. Roy E. Appleman, South to the Naktong, North to the Yalu, Government Printing Office, 1961.
3. Stephen L.Y. Gammons, The UN Offensive: 16 September-2 November 1950, U.S. Army Center of Military History, 2000.
4. Edwin H. Simmons, Over the Seawall: U.S. Marines at Inchon, History and Museums Division, Headquarters, U.S. Marine Corps, 2000.
5. Joseph H. Alexander, Battle of the Barricades: U.S. Marines in the Recapture of Seoul, History and Museums Division, Headquarters, U.S. Marine Corps, 2000.
6. Lynn Montross and Nicholas A. Canzona, The Inchon-Seoul Operation, Historical Branch, G-3, Headquarters, U.S. Marine Corps, 1955.
7. Ralph Grishman and Beth Sundheim, "Message Understanding Conference-6: A Brief History," in COLING 1996 Volume 1: The 16th International Conference on Computational Linguistics, pp. 466-471, 1996.
8. Linguistic Data Consortium, ACE (Automatic Content Extraction) English Annotation Guidelines for Events, Version 5.4.3, 2005.
9. James Pustejovsky, José M. Castaño, Robert Ingria, Roser Saurí, Robert J. Gaizauskas, Andrea Setzer, and Graham Katz, "TimeML: Robust Specification of Event and Temporal Expressions in Text," in New Directions in Question Answering, pp.

28-34, 2003.
10. James Pustejovsky, Patrick Hanks, Roser Saurí, Andrew See, Robert Gaizauskas, Andrea Setzer, Dragomir Radev, Beth Sundheim, David Day, Lisa Ferro, and Marcia Lazo, "The TIMEBANK Corpus," in Corpus Linguistics 2003, pp. 647-656, 2003.
11. James Pustejovsky and Amber Stubbs, Natural Language Annotation for Machine Learning, O'Reilly Media, 2012.
12. Pontus Stenetorp, Sampo Pyysalo, Goran Topić, Tomoko Ohta, Sophia Ananiadou, and Jun'ichi Tsujii, "brat: a Web-based Tool for NLP-Assisted Text Annotation," in Proceedings of the Demonstrations at the 13th Conference of the European Chapter of the Association for Computational Linguistics, pp. 102-107, 2012.